

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO

FABIOLA DIAS CARVALHO

MERCADO BRASILEIRO DE COMBUSTÍVEIS

Pipeline de dados em nuvem para análise de volume declarado, concentração, preços de
revenda e agentes regulados

Rio de Janeiro
2026

FABIOLA DIAS CARVALHO

MERCADO BRASILEIRO DE COMBUSTÍVEIS

Relatório apresentado à Pontifícia Universidade Católica do Rio de Janeiro como parte da avaliação do MVP de Engenharia de Dados. O trabalho documenta a construção de um pipeline em nuvem no Databricks, com dados públicos da Agência Nacional do Petróleo, Gás Natural e Biocombustíveis.

Resumo

Este trabalho apresenta a construção de um pipeline de dados em nuvem para analisar o mercado brasileiro de gasolina C e etanol hidratado com bases públicas da Agência Nacional do Petróleo, Gás Natural e Biocombustíveis. O pipeline foi implementado no Databricks e integra informações de movimentação logística, vendas declaradas ao Sistema de Informações de Movimentação de Produtos, pesquisa de preços de revenda, vendas municipais anuais e cadastro de revendedores. O núcleo mensal cobre 54 meses, de janeiro de 2022 a junho de 2026, enquanto a camada municipal permanece no intervalo publicado de 2022 a 2024.

A arquitetura preserva os arquivos de origem na camada Bronze, padroniza tipos, chaves e regras de qualidade na Silver e disponibiliza dimensões, fatos e marts na Gold. A execução final produziu 52 tabelas gerenciadas, 650 atributos catalogados e 43 regras de qualidade. A validação terminou com status aprovado. Entre 2022 e 2026, sempre considerando janeiro a junho, o volume declarado de gasolina C passou de 15,941 para 19,215 bilhões de litros, e o etanol hidratado passou de 8,461 para 12,255 bilhões. Em 2026, a Vibra liderou a gasolina C com 21,88% do volume da Logística 02. No etanol, Ipiranga, Raízen e Vibra ficaram próximas, com participações de 11,44%, 11,40% e 11,00%.

A comparação entre SIMP e Logística 02 mostrou totais muito próximos para gasolina C e diferenças crescentes para etanol. Essas diferenças foram mantidas como resultado de escopo, sem ajuste artificial. A pesquisa de preços foi tratada como amostral e acompanhada por medidas de cobertura. As correlações foram usadas apenas para descrever associações entre volume, concentração e preço, sem interpretação causal.

Palavras-chave: engenharia de dados; Databricks; ANP; combustíveis; lakehouse; qualidade de dados; market share.

Abstract

This report documents a cloud data pipeline built in Databricks to analyze the Brazilian gasoline C and hydrated ethanol market using public datasets published by the Brazilian National Agency of Petroleum, Natural Gas and Biofuels. The pipeline combines declared logistics volumes, SIMP records by regulated agent and destination market, retail price surveys, annual municipal sales and the current register of fuel retailers. Monthly sources cover January 2022 through June 2026, while municipal data cover 2022 through 2024.

The solution follows Bronze, Silver and Gold layers. It preserves source files and lineage, standardizes types and keys, applies data quality controls and materializes analytical facts, dimensions and marts. The final execution produced 52 managed tables, cataloged 650 attributes and ran 43 quality rules. Results show growth in declared volumes, different concentration patterns across states, a leading position for Vibra in gasoline C, a more balanced structure among Ipiranga, Raízen and Vibra in hydrated ethanol, and relevant scope differences between SIMP and Logística 02 for ethanol.

Keywords: data engineering; Databricks; ANP; fuels; lakehouse; data quality; market share.

Lista de figuras

Figura 1 - Cobertura temporal confirmada no Databricks SQL	13
Figura 2 - Fluxo lógico e quantidade de tabelas por camada	15
Figura 3 - Grafo da execução final do job Engenharia-de-Dados	19
Figura 4 - Distribuição das regras de qualidade na execução final	21
Figura 5 - Regras de qualidade consultadas no Databricks	22
Figura 6 - Volume declarado no primeiro semestre de cada ano	23
Figura 7 - Resultado do volume nacional no Databricks SQL	24
Figura 8 - Cinco maiores vendedores declarados no primeiro semestre de 2026	25
Figura 9 - Ranking de vendedores no Databricks SQL	25
Figura 10 - Evolução das empresas selecionadas nos primeiros semestres	26
Figura 11 - Concentração estadual consultada no Databricks SQL	27
Figura 12 - Mediana das medianas estaduais no primeiro semestre	28
Figura 13 - Resultado de preços no Databricks SQL	28
Figura 14 - Correlações descritivas no Databricks SQL	29
Figura 15 - Volumes do SIMP e da Logística 02 no primeiro semestre	30
Figura 16 - Comparação entre SIMP e Logística 02 no Databricks SQL	31
Figura 17 - Distribuição por mercado destinatário no SIMP	32
Figura 18 - Cobertura municipal consultada no Databricks SQL	33

Lista de tabelas

Tabela 1 - Perguntas de análise	9
Tabela 2 - Fontes granularidades e papéis no projeto	11
Tabela 3 - Arquivos coletados e persistência	12
Tabela 4 - Cobertura temporal por fonte	12
Tabela 5 - Campos de linhagem	13
Tabela 6 - Tabelas analíticas granularidades e finalidades.....	15
Tabela 7 - Chaves e condições de integração	16
Tabela 8 - Exemplos do catálogo de dados	16
Tabela 9 - Sequência de tarefas do job	18
Tabela 10 - Identificação da execução final	19
Tabela 11 - Conteúdo publicado no GitHub.....	20
Tabela 12 - Resultado das regras de qualidade	22
Tabela 13 - Exemplos de concentração estadual	27
Tabela 14 - Correlações entre volume concentração e preço	29
Tabela 15 - Maiores agentes regulados no primeiro semestre de 2026.....	32
Tabela 16 - Cobertura municipal de venda e preço	33
Tabela 17 - Respostas às perguntas do projeto.....	36
Tabela 18 - Limitações e tratamento adotado.....	37
Tabela 19 - Atendimento aos requisitos do professor	41
Tabela 20 - Evidências e localização no relatório	42

Sumário

1 Introdução	8
2 Fontes e coleta	11
3 Arquitetura e modelagem	15
4 Transformação e carga	18
5 Qualidade dos dados	21
6 Análises e resultados	23
7 Repositório público e reprodutibilidade	34
8 Respostas às perguntas do projeto	36
9 Limitações	37
10 Autoavaliação	38
11 Conclusão	39
Referências	40
Apêndice A Atendimento aos requisitos	41
Apêndice B Matriz de evidências	42

1 Introdução

1.1 Contexto do trabalho

O abastecimento de combustíveis produz registros com diferentes unidades, granularidades e finalidades regulatórias. Uma base descreve a movimentação declarada por vendedor e Unidade da Federação; outra detalha agentes regulados e mercados destinatários; a pesquisa de preços observa postos e datas de coleta; e a publicação municipal apresenta volumes anuais. Analisar essas fontes como se fossem equivalentes criaria associações que os dados não sustentam.

A ANP informa que os volumes do painel de combustíveis líquidos são declaratórios e podem ser reprocessados. O painel e sua base são atualizados duas vezes por mês. Por isso, o pipeline registra a data de coleta, o arquivo, o tamanho, o hash SHA-256, o lote de ingestão e a execução que gerou cada resultado. Essa identificação permite repetir o processamento sem misturar versões distintas da fonte (ANP, 2026a).

1.2 Problema de pesquisa

O problema central consiste em organizar as fontes da ANP em uma estrutura que permita acompanhar a evolução do volume declarado, a participação dos vendedores, a concentração estadual, o comportamento dos preços e a distribuição por agentes regulados, mantendo as limitações de cada base. A pergunta que orientou o trabalho foi:

Como evoluiu o volume de gasolina C e etanol hidratado declarado por vendedor nas Unidades da Federação entre janeiro de 2022 e junho de 2026, qual é a estrutura de concentração observada e o que a base SIMP acrescenta sobre agentes regulados, mercados de destino e preços?

1.3 Objetivos

O objetivo geral foi construir um pipeline de dados em nuvem que integrasse as bases selecionadas, preservasse a linhagem desde o arquivo bruto e produzisse tabelas analíticas reproduzíveis. Os objetivos específicos foram:

- coletar e registrar a procedência dos arquivos oficiais da ANP;
- modelar dados em camadas Bronze, Silver e Gold, com fatos e dimensões na camada analítica;
- documentar atributos, domínios, unidades, valores observados e regras de qualidade;
- calcular volume, participação, ranking, Top 3 e HHI por produto e território;
- comparar a Logística 02 com o SIMP sem tratar as duas fontes como equivalentes;

- relacionar preço, volume e concentração somente em granularidades compatíveis;
- registrar evidências de execução, qualidade e resultados no Databricks.

1.4 Perguntas de análise

Tabela 1 - Perguntas de análise

Nº	Pergunta
1	Quais vendedores concentram os maiores volumes declarados por produto?
2	Como mudaram a participação do líder, o Top 3 e o HHI por UF?
3	Como evoluíram Vibra, Ipiranga, Raízen e ALE nos primeiros semestres?
4	Como se comportaram os preços medianos, a dispersão e a cobertura?
5	Como preço, volume e concentração variaram conjuntamente?
6	Em que medida Logística 02 e vendas municipais são conciliáveis?
7	Que contexto o cadastro atual de revendedores acrescenta?
8	Quais agentes regulados lideram no SIMP e como o volume se distribui por destino?

Fonte: elaboração própria.

1.5 Delimitação do escopo

O recorte nacional considera gasolina C comum e etanol hidratado comum. As comparações anuais usam janeiro a junho, porque 2026 está disponível somente até junho. A camada municipal não foi projetada além de 2024. O trabalho descreve volumes declarados, estrutura de participação, preços observados e qualidade das bases; não estima demanda futura, margem comercial, causalidade de preços nem participação histórica de bandeiras na rede varejista.

1.6 Estratégia metodológica

O trabalho foi organizado como um estudo descritivo de engenharia de dados. Primeiro, foram definidas as perguntas e as unidades de análise. Depois, foram escolhidas fontes capazes de responder a cada pergunta sem forçar uma chave inexistente. Em seguida, os arquivos foram coletados, registrados, carregados e transformados. Somente após a validação das tabelas foram executadas as consultas analíticas. Essa ordem atende à orientação do MVP de definir o problema antes da busca e de manter as perguntas originais mesmo quando a resposta é parcial (PUC-Rio, 2026).

A opção pelo Databricks decorreu de três necessidades: persistir arquivos e tabelas na nuvem, executar transformações distribuídas com Spark e manter o pipeline em tarefas encadeadas. A arquitetura em camadas foi adotada porque separa o dado recebido da

interpretação analítica. O resultado de uma análise pode, assim, ser rastreado até o arquivo original, sem que uma limpeza na Silver apague o registro mantido na Bronze.

A análise empregou SQL e funções Spark para agregações, janelas, percentis aproximados, correlações e verificações de qualidade. Os gráficos apresentados neste relatório foram produzidos a partir das tabelas Gold. As capturas do Databricks mostram o código ou o resultado tabular que sustenta cada conclusão; por isso, elas aparecem próximas do texto correspondente, e não reunidas sem contexto ao final.

2 Fontes e coleta

2.1 Bases utilizadas

Foram utilizados cinco conjuntos de dados institucionais. Os arquivos brutos permanecem no Volume gerenciado do Databricks; o repositório contém código, configurações e documentação. A separação reduz o risco de publicar arquivos grandes ou credenciais e permite reproduzir a coleta a partir das URLs registradas.

Tabela 2 - Fontes granularidades e papéis no projeto

Fonte	Granularidade	Cobertura	Uso
Logística 02	vendedor x UF x produto x mês	2022-01 a 2026-06	volume, ranking e concentração
SIMP combustíveis líquidos	agente x destino x UF x produto x mês	2022-01 a 2026-06	agentes, mercados e comparação
Preços de revenda	posto x produto x data	2022-01 a 2026-06	preço, dispersão e cobertura
Vendas municipais	município x produto x ano	2022 a 2024	escala e reconciliação anual
Cadastro de revendedores	CNPJ x fotografia de extração	extração atual	contexto de rede e bandeira

Fonte: elaboração própria com dados da ANP.

2.2 Procedência e condições de uso

A ANP disponibiliza os dados em seu portal de dados abertos e informa que eles podem ser visualizados, estudados e trabalhados por cidadãos, pesquisadores e agentes econômicos. As páginas institucionais fazem referência ao Decreto nº 8.777, de 11 de maio de 2016, que instituiu a Política de Dados Abertos do Poder Executivo federal. Não foram usados dados internos, sigilosos ou obtidos por raspagem de páginas protegidas (ANP, 2026b).

O manifesto de download registra 14 arquivos originais: nove arquivos semestrais da pesquisa de preços, dois CSVs de vendas municipais, o cadastro de revendedores, o arquivo da Logística 02 e o arquivo liquidos.zip. Para cada item foram armazenados URL, horário de download, tamanho em bytes, hash SHA-256 e arquivos extraídos. O arquivo liquidos.zip, por exemplo, foi registrado com 21.635.069 bytes e hash a551a03bdf3ea12c37ea53452f5a39bacef40c2319675c6fdb3381feef05a4ad.

2.3 Coleta e armazenamento

A coleta foi realizada por scripts que verificam o status da resposta, o tipo de arquivo e o hash antes da preparação. Os ZIPs foram mantidos na zona raw e extraídos para diretórios separados. O Databricks recebeu os 14 arquivos, três CSVs de configuração e o manifesto em

um Volume do Unity Catalog. Os arquivos de configuração definem mapeamento de produtos, agrupamento de empresas e descrições do catálogo.

Tabela 3 - Arquivos coletados e persistência

Item	Quantidade	Persistência
Arquivos oficiais	14	Volume gerenciado
CSVs preparados	11	Volume e tabelas Bronze
Arquivos de configuração	3	Volume e repositório
Manifesto de origem	1	Volume metadata

Fonte: manifesto de coleta do projeto.

2.4 Cobertura temporal


As três fontes mensais possuem 54 períodos no recorte analítico. A base municipal termina em 2024 e não foi extrapolada. Quando 2026 participa de uma comparação, todos os anos são reduzidos ao primeiro semestre.

Tabela 4 - Cobertura temporal por fonte

Fonte	Início	Fim	Períodos
Logística 02	jan. 2022	jun. 2026	54 meses
SIMP líquidos	jan. 2022	jun. 2026	54 meses
Preços	jan. 2022	jun. 2026	54 meses
Vendas municipais	2022	2024	3 anos

Fonte: tabelas Silver consultadas no Databricks.

Figura 1 - Cobertura temporal confirmada no Databricks SQL



Fonte: captura da consulta executada no Databricks em 2026.

2.5 Linhagem e atualização

A linhagem foi mantida no nível do arquivo e da execução. Assim, cada linha processada pode ser associada à publicação recebida, ao lote que a carregou e ao processamento que gerou as tabelas analíticas. Quando a ANP republica uma base, o novo arquivo recebe outro registro no manifesto, sem substituir silenciosamente a versão anterior.

Tabela 5 - Campos de linhagem

Campo	Registro	Finalidade
url_origem	endereço oficial da ANP	repetir a coleta
arquivo_origem	nome recebido ou extraído	localizar o insumo
sha256	assinatura do conteúdo	distinguir versões
lote_id	identificador da ingestão	isolar a carga Bronze
execucao_id	identificador do processamento	rastrear Silver e Gold
data_ingestao	data e hora em UTC	ordenar e auditar as cargas

Fonte: elaboração própria.

2.6 Origem de cada informação

A Logística 02 foi a base principal para as perguntas sobre vendedores, porque contém razão social, UF de destino, produto, mês e volume. O arquivo líquidos.zip foi usado para a visão complementar do SIMP, na qual aparecem o agente regulado e o mercado destinatário. A

série histórica de preços forneceu preço de venda, município, estabelecimento e data de coleta. As vendas municipais trouxeram o total anual por município e produto. Por fim, o cadastro de revendedores foi utilizado apenas como fotografia atual da rede, sem retroceder a bandeira informada na data de extração para anos anteriores (ANP, 2026c, 2026d, 2026e, 2026f, 2026g).

Essa separação responde a uma questão central do projeto: dados que tratam do mesmo setor não são necessariamente intercambiáveis. O vendedor que declara uma operação logística pode não representar a bandeira do posto que realizou a venda ao consumidor. Do mesmo modo, a pesquisa de preços observa uma amostra de postos, enquanto a venda municipal é uma publicação anual agregada. O cruzamento só foi realizado depois que cada fonte foi reduzida a uma granularidade compatível.

2.7 Uso de dados abertos e aspectos éticos

A coleta utilizou arquivos disponibilizados no portal oficial de dados abertos da ANP. Não foi necessário contornar autenticação, automatizar páginas restritas ou coletar dados pessoais fora da finalidade regulatória das publicações. Os arquivos foram acessados por endereços institucionais e mantidos sem alteração na zona raw. A documentação registra a procedência e a data de acesso, conforme a orientação do professor para explicitar licença e condições de uso quando aplicáveis (ANP, 2026b; PUC-Rio, 2026).


Os dados brutos não foram publicados no GitHub. Essa decisão evita duplicar arquivos volumosos, reduz o risco de versionar informações desnecessárias e preserva a atualização pela fonte oficial. O repositório contém os scripts de coleta, o manifesto esperado e a documentação necessária para obter novamente os arquivos.

3 Arquitetura e modelagem

3.1 Arquitetura do lakehouse

O projeto segue a arquitetura em camadas recomendada para lakehouses. A Bronze preserva o estado recebido da fonte e acrescenta metadados de origem. A Silver realiza tipagem, normalização, conciliação e sinalização de qualidade. A Gold organiza dimensões, fatos, reconciliações e marts voltados às perguntas do trabalho. Essa separação melhora a possibilidade de reprocessamento e auditoria (Databricks, 2026).

Figura 2 - Fluxo lógico e quantidade de tabelas por camada



Fonte: elaboração própria.

3.2 Modelo analítico

A camada Gold foi modelada como uma constelação de fatos. Cada fonte conserva sua granularidade e compartilha dimensões apenas quando existe uma chave compatível. Esse desenho evita atribuir o preço de um posto a um vendedor da Logística 02 ou tratar uma bandeira como se fosse o agente regulado do SIMP.

Tabela 6 - Tabelas analíticas granularidades e finalidades

Tabela	Granularidade	Finalidade
gold_fato_venda_empresa_uf_mes	vendedor x UF x produto x mês	volume líquido declarado
gold_fato_participacao_vendedor_uf_mes	vendedor x UF x produto x mês	participação e posição
gold_fato_concentracao_uf_mes	UF x produto x mês	HHI, líder e Top 3
gold_fato_venda_simp_agente_uf_mes	agente x UF x produto x mês	volume e participação SIMP
gold_fato_preco_uf_mes	UF x produto x mês	mediana, percentis e cobertura
gold_fato_mercado_municipio_anual	município x produto x ano	preço e venda anual
gold_comparacao_simp_logistica_uf_mes	UF x produto x mês	volumes paralelos e diferença

Fonte: catálogo de dados do projeto.

3.3 Chaves e regras de integração

Tabela 7 - Chaves e condições de integração

Relação	Chave	Condição
Preço e município	município normalizado + UF	conciliação com código IBGE
Preço e venda municipal	código IBGE + ano + produto	mart anual 2022 a 2024
Volume e preço estadual	UF + mês + produto	fontes agregadas antes da junção
SIMP e Logística 02	UF + mês + produto	comparação de escopo
Cadastro e preços	CNPJ	fotografia atual, sem reconstrução histórica

Fonte: elaboração própria.

Vendedor, agente regulado e bandeira são dimensões distintas. A normalização de nomes foi usada para diagnóstico e agrupamentos explicitamente documentados; ela não cria equivalência jurídica por semelhança textual.

3.4 Catálogo de dados

O catálogo combina uma parte definida em arquivo de configuração e outra calculada na execução. Para cada atributo, a tabela `gold_catalogo_atributos` registra nome, tipo Spark, descrição, unidade, domínio esperado, quantidade de linhas, nulos, valores distintos, mínimo, máximo e categorias mais frequentes quando aplicável. A execução final catalogou 650 atributos.

Tabela 8 - Exemplos do catálogo de dados

Atributo	Tipo	Domínio	Controle
<code>data_referencia</code>	data	2022-01-01 a 2026-06-01 no núcleo mensal	cobertura temporal
<code>uf</code>	texto	27 siglas válidas	registros inválidos ficam fora do agregado
<code>preco_venda</code>	decimal	maior que zero	flag <code>preco_valido</code>
<code>volume_liquido_litros</code>	decimal	negativos podem ser ajustes	ajuste sinalizado e preservado
<code>participacao_pct</code>	decimal	0 a 100	somente saldos positivos
<code>hhi</code>	decimal	0 a 10.000	soma dos quadrados das participações
<code>codigo_ibge</code>	texto	sete dígitos	conciliação municipal

Fonte: `gold_catalogo_atributos`.

3.5 Justificativa das decisões de modelagem

A decisão mais importante foi não construir uma tabela única com todas as fontes. Embora essa alternativa simplificasse algumas consultas, ela repetiria preços para cada vendedor, misturaria periodicidades mensais e anuais e produziria associações sem

correspondência direta. A constelação de fatos mantém cada evento em sua granularidade original e cria tabelas de comparação somente depois da agregação para chaves comuns.

As dimensões de produto, tempo, território, vendedor e agente regulado foram separadas porque representam conceitos diferentes. O mapeamento de produto resolve variações de grafia sem alterar o valor original. A dimensão territorial usa a sigla da UF nas fontes mensais e o código IBGE nas análises municipais. Vendedor e agente regulado permanecem em estruturas próprias; o agrupamento de empresas é aplicado apenas nas análises que declaram essa regra.

O modelo foi considerado adequado quando permitiu responder às perguntas sem duplicar medidas, manteve a origem de cada linha e tornou explícito o nível em que cada cruzamento era válido. O resultado foi uma camada Gold com fatos reutilizáveis e marts específicos para cobertura, reconciliação, concentração e comparação entre fontes.

4 Transformação e carga

4.1 Sequência de execução

O job Engenharia-de-Dados possui seis tarefas encadeadas. A dependência entre as tarefas impede que uma análise seja executada sobre tabelas incompletas. A carga Bronze usa append por lote; as etapas Silver e Gold recalculam a execução selecionada.

Tabela 9 - Sequência de tarefas do job

Ordem	Tarefa	Resultado
1	preparar_arquivos	extraí e organiza CSVs
2	ingestao_bronze	persiste o lote bruto
3	transformacao	gera Silver, dimensões, fatos e marts
4	qualidade	perfila atributos e executa regras
5	analises	executa consultas do problema
6	validacao	confere cobertura, objetos e resultado final

Fonte: job Engenharia-de-Dados no Databricks.

4.2 Tratamentos na camada Silver

- conversão de datas, decimais e unidades para tipos Spark;
- remoção de formatação do CNPJ e validação do padrão de 14 dígitos;
- normalização de municípios e conciliação com o código IBGE;
- mapeamento versionado de nomes de produtos para gasolina C e etanol hidratado;
- conversão do volume SIMP de mil metros cúbicos para litros;
- geração de chaves determinísticas e flags de duplicidade, validade e recorte;
- preservação do valor original, arquivo, lote e data de ingestão.

Os registros problemáticos não foram apagados para melhorar indicadores. A Silver os mantém com flags, enquanto as agregações usam condições explícitas. Essa decisão permite revisar uma exceção sem perder o dado recebido.

4.3 Cálculos na camada Gold

O volume por vendedor é somado por UF, produto e mês. Os rankings consideram saldos positivos. A participação é o volume positivo do vendedor dividido pelo total positivo da respectiva UF, mês e produto. O HHI é calculado pela soma dos quadrados das participações percentuais. O resultado varia de zero a 10.000: valores maiores indicam maior concentração no conjunto observado.

Os preços permanecem no nível de posto e data. Depois, a camada Gold calcula estatísticas semanais por município e mensais por UF. A mediana foi escolhida para reduzir o peso de valores extremos. Toda medida de preço acompanha quantidade de coletas, postos, municípios e semanas.

4.4 Execução final


Tabela 10 - Identificação da execução final

Controle	Valor
Usuária	fabidatabricks@gmail.com
Schema	workspace.anp_combustiveis_br_2022_2026
Job	Engenharia-de-Dados 437094880624974
Run	668282086141894 SUCCESS
Lote	anp_br_20260919T171358Z_ce493196
Execução	anp_br_20260919T171358Z_ce493196_ab91045f
Tabelas	52 tabelas gerenciadas

Fonte: detalhes da execução no Databricks.

Endereço da execução: [Databricks Job Run 668282086141894](#)

Figura 3 - Grafo da execução final do job Engenharia-de-Dados com seis tarefas concluídas e status Succeeded



Fonte: captura da execução realizada na conta da autora no Databricks em 19 set. 2026.

4.5 Reprodutibilidade e controle de versão

O repositório público reúne apenas os elementos necessários para repetir e avaliar o trabalho. Os dados brutos e as credenciais permanecem fora do GitHub. A execução no Databricks é composta pelos mesmos notebooks versionados, na ordem apresentada na Seção 4.1.

Tabela 11 - Conteúdo publicado no GitHub

Conteúdo	Função
README.md	apresenta objetivo, fontes, recorte e modo de execução
config/	mantém o ambiente de exemplo, o catálogo e os mapeamentos de produtos e empresas
data/README.md	explica onde os arquivos locais são esperados, sem publicar os dados brutos
docs/	documenta objetivo, fontes, linhagem, modelo, catálogo e execução no Databricks
notebooks/	implementa preparação, setup, Bronze, transformação, qualidade, análises e validação
scripts/	contém os utilitários de download e inspeção dos arquivos oficiais
tests/	verifica os utilitários de coleta e inspeção
Makefile, pytest.ini e requirements-dev.txt	padronizam as verificações e dependências de desenvolvimento

Fonte: repositório público Engenharia-de-Dados.

Repositório: [diasfabi7-prog/Engenharia-de-Dados](https://github.com/diasfabi7-prog/Engenharia-de-Dados)

4.6 Persistência e possibilidade de reexecução

A ingestão Bronze é controlada pelo identificador do lote. A execução não substitui silenciosamente o conteúdo recebido: um novo conjunto de arquivos gera outro lote e mantém o anterior disponível para auditoria. Nas camadas tratadas, o identificador da execução acompanha as tabelas e permite saber qual transformação produziu o resultado consultado.


Essa estratégia foi adotada porque as bases declaratórias podem ser republicadas. Se um arquivo mudar, o hash e a data de coleta tornam a alteração observável. A reexecução pode partir do mesmo lote para validar o código ou de um lote novo para atualizar a análise. No processamento final, as seis tarefas terminaram com sucesso e a validação confirmou 52 tabelas gerenciadas, 54 meses nas três fontes mensais e o recorte municipal de 2022 a 2024.

5 Qualidade dos dados

5.1 Método de avaliação

A qualidade foi avaliada por atributo e por regra. O perfil calcula quantidade de linhas, nulos, distintos, valores mínimos e máximos e categorias frequentes. As 43 regras cobrem integridade, domínio, cobertura temporal, mapeamento de produto, validade geográfica, duplicidade, conciliação entre fontes e disponibilidade para análise.

Figura 4 - Distribuição das regras de qualidade na execução final



Fonte: gold_resumo_qualidade.

5.2 Dimensões verificadas

A completude foi medida pela presença dos campos essenciais de data, produto, território, entidade e medida. A validade verificou datas, siglas de UF, códigos IBGE, CNPJ, produtos mapeados e valores numéricos. A unicidade foi analisada na chave correspondente a cada fonte, sem impor ao arquivo bruto uma chave que ele não possui. A consistência comparou totais, cobertura temporal, unidades e relações entre Silver e Gold. A rastreabilidade conferiu arquivo, lote, execução e data de ingestão.

Nem toda ocorrência recebeu o mesmo tratamento. Uma falha em campo obrigatório para a análise impede a linha de entrar no agregado, mas a linha permanece na Silver. Um volume negativo do SIMP pode representar ajuste declaratório e, por isso, é preservado e sinalizado. Uma diferença entre fontes aparece como resultado informativo ou atenção, pois não existe base metodológica para escolher um dos totais e apagar o outro.

5.3 Resultado da execução

Tabela 12 - Resultado das regras de qualidade

Status	Regras	Ocorrências	Interpretação
Aprovada	22	0	controle sem ocorrência
Atenção	7	47.685	exceção preservada e tratada
Informativa	14	927.192	perfil e cobertura, sem reprovação

Fonte: gold_resumo_qualidade.

As 47.685 ocorrências de atenção não representam 47.685 linhas independentes. O arquivo de preços do primeiro semestre de 2025 continha 9.114 linhas vazias, e as mesmas linhas acionaram cinco regras: preço, CNPJ, município, produto e data. Elas permaneceram auditáveis na Silver e foram excluídas das agregações pelas flags de validade. O resultado também registrou 1.667 combinações com preço, mas sem venda municipal correspondente, e 448 linhas do SIMP com volume ausente ou negativo.

Figura 5 - Regras de qualidade consultadas no Databricks após a reexecução final

```

122 -- 30_municipal_2022_2024.png
123 SELECT ano, produto_analitico,
124        SUM(municipios_com_venda) AS municipios_com_venda,
125        SUM(municipios_com_preco) AS municipios_com_preco,
126        SUM(municipios_publicaveis) AS municipios_publicaveis,
127        ROUND(100.0 * SUM(municipios_com_preco) /
128              NULLIF(SUM(municipios_com_venda), 0), 2) AS cobertura_preco_pct
129 FROM gold_cobertura_pesquisa
130 GROUP BY ano, produto_analitico
131 ORDER BY produto_analitico, ano;
132
133 -- 31_qualidade_2026.png
134 SELECT regra_id, tabela, qtd_afetada, pct_afetada, status
135 FROM gold_resultado_regra_qualidade
136 ORDER BY status, regra_id;
137

```

	regra_id	tabela	qtd_afetada	pct_afetada	status
1	INTEGRIDADE_001	gold_fato_preco_coletado	0	0	APROVADA
2	LOGISTICA_001	silver_venda_empresa_uf_mes	0	0	APROVADA
3	LOGISTICA_003	silver_venda_empresa_uf_mes	0	0	APROVADA
4	LOGISTICA_004	silver_venda_empresa_uf_mes	0	0	APROVADA
5	LOGISTICA_005	silver_venda_empresa_uf_mes	0	0	APROVADA
6	LOGISTICA_007	silver_venda_empresa_uf_mes	0	0	APROVADA
7	PARTICIPACAO_001	gold_fato_participacao_vendedor_uf_mes	0	0	APROVADA

37 rows 19.279s runtime See performance (10) Optimize Refreshed Now

Fonte: captura da tabela gold_resultado_regra_qualidade no Databricks em 2026.

5.4 Ajuste da regra municipal


A primeira execução sinalizou 30.685 repetições da chave município, produto e ano. A investigação mostrou que todas pertenciam a períodos históricos preservados fora do recorte de 2022 a 2024. A regra foi corrigida para avaliar apenas dentro do recorte analítico. Depois da reexecução de qualidade, análises e validação, VENDA_MUNICIPIO_004 registrou zero ocorrências e status aprovado. A correção não alterou a ingestão nem os resultados do recorte.

6 Análises e resultados

6.1 Evolução do volume no primeiro semestre

O primeiro semestre foi usado em todos os anos para manter 2026 comparável aos períodos anteriores. A gasolina C passou de 15,941 bilhões de litros em 2022 para 19,215 bilhões em 2026, aumento de 20,5%. O etanol hidratado passou de 8,461 para 12,255 bilhões, aumento de 44,8%. A gasolina cresceu em 2023, recuou em 2024 e voltou a avançar. O etanol caiu em 2023 e mudou de patamar em 2024.

Figura 6 - Volume declarado no primeiro semestre de cada ano



Fonte: Logística 02 processada no Databricks.

Figura 7 - Resultado do volume nacional no Databricks SQL com recorte de janeiro a junho

Run all (1000) Just now (1s) workspace: anp_combustiveis_br_2022...

```

1 USE CATALOG workspace;
2 USE SCHEMA anp_combustiveis_br_2022_2026;
3
4 SELECT ano,
5        produto_analitico,
6        ROUND(SUM(volume_total_liquido_uf_litros) / 1000000000.0, 3) AS volume_bilhoes_litros,
7        COUNT(DISTINCT uf) AS ufs_com_volume
8 FROM gold_mart_mercado_uf_mes
9 WHERE volume_disponivel AND mes <= 6
10 GROUP BY ano, produto_analitico
11 ORDER BY produto_analitico, ano;

```

Add parameter

Results 3 of 3 Table

	ano	produto_analitico	volume_bilhoes_litros	ufs_com_volume
1	2022	ETANOL_HIDRATADO	8.461	27
2	2023	ETANOL_HIDRATADO	7.777	27
3	2024	ETANOL_HIDRATADO	12.216	27
4	2025	ETANOL_HIDRATADO	12.236	27
5	2026	ETANOL_HIDRATADO	12.255	27
6	2022	GASOLINA_C	15.941	27
7	2023	GASOLINA_C	18.539	27

10 rows 0.991s runtime See performance (3) Checked for improvements Refreshed Now


Fonte: captura da consulta executada no Databricks em 2026.

Esses valores representam volume declarado na base logística. Eles não devem ser descritos como consumo final medido diretamente, pois a fonte registra operações do mercado de abastecimento e pode receber reprocessamentos posteriores.

6.2 Market share por vendedor declarado


Na gasolina C, a Vibra liderou o primeiro semestre de 2026 com 4,204 bilhões de litros e 21,88% do volume positivo. Ipiranga teve 17,68% e Raízen, 15,61%. As três somaram 55,17%. No etanol hidratado, a diferença entre as três primeiras foi inferior a meio ponto percentual: Ipiranga registrou 11,44%, Raízen 11,40% e Vibra 11,00%.

Figura 8 - Cinco maiores vendedores declarados no primeiro semestre de 2026



Fonte: gold_fato_venda_empresa_uf_mes.

Figura 9 - Ranking de vendedores de gasolina C e etanol hidratado no Databricks SQL



Fonte: captura da consulta executada no Databricks em 2026.


O denominador inclui todos os vendedores com saldo positivo na Logística 02. Por isso, a medida é chamada de participação no volume declarado por vendedor. Ela não representa automaticamente participação da bandeira na rede varejista.

6.3 Evolução de Vibra Ipiranga Raízen e ALE

A comparação usa janeiro a junho de cada ano e mantém as razões sociais publicadas, sem somar variantes societárias. Na gasolina C, a Vibra permaneceu líder, mas sua participação passou de 24,76% para 21,88% entre 2022 e 2026. Ipiranga passou de 18,48% para 17,68%, Raízen de 17,14% para 15,61% e ALE de 3,08% para 3,14%.

No etanol, as quatro linhas perderam participação no período. Raízen passou de 16,45% para 11,40%; Vibra, de 14,78% para 11,00%; Ipiranga, de 14,71% para 11,44%; e ALE, de 1,76% para 1,21%. O movimento sugere maior dispersão do volume entre os vendedores publicados, mas não prova mudança de concorrência sem examinar entrada, saída e relações societárias.

Figura 10 - Evolução das empresas selecionadas nos primeiros semestres



Fonte: Logística 02 processada no Databricks.

6.4 Concentração por Unidade da Federação

A agregação nacional esconde estruturas estaduais muito distintas. No etanol do Amapá, o HHI caiu de 8.251 em 2022 para 4.200 em 2026. A participação do líder caiu de 90,7% para 59,2%, mas continuaram apenas quatro vendedores positivos. No Rio Grande do Sul, o HHI caiu de 4.438 para 1.056, a participação do líder passou de 63,5% para 23,4% e o número de vendedores aumentou de 26 para 33.

Tabela 13 - Exemplos de concentração estadual

UF	Produto	HHI 2022 H1	HHI 2026 H1	Vendedores 2026	Líder 2026
AP	Etanol	8.251	4.200	4	59,2%
RS	Etanol	4.438	1.056	33	23,4%
AP	Gasolina C	5.030	4.846	5	52,7%
RS	Gasolina C	1.826	1.538	23	24,0%

Fonte: cálculo sobre a Logística 02.

Figura 11 - Concentração estadual medida pelo HHI entre os primeiros semestres de 2022 e 2026

```

20 SELECT uf, produto_analitico,
21        MAX(CASE WHEN ano = 2022 THEN hhi END) AS hhi_2022h1,
22        MAX(CASE WHEN ano = 2026 THEN hhi END) AS hhi_2026h1,
23        MAX(CASE WHEN ano = 2026 THEN vendedores_positivos END) AS vendedores_2026h1,
24        MAX(CASE WHEN ano = 2026 THEN lider_pct END) AS lider_2026h1_pct
25 FROM resumo
26 GROUP BY uf, produto_analitico
27 )
28 SELECT uf, produto_analitico,
29        ROUND(hhi_2022h1, 0) AS hhi_2022h1,
30        ROUND(hhi_2026h1, 0) AS hhi_2026h1,
31        ROUND(hhi_2026h1 - hhi_2022h1, 0) AS variacao_hhi,
32        vendedores_2026h1,
33        ROUND(lider_2026h1_pct, 1) AS lider_2026h1_pct
34 FROM comparacao
35 QUALIFY ROW_NUMBER() OVER (PARTITION BY produto_analitico ORDER BY ABS(hhi_2026h1 - hhi_2022h1) DESC, uf) <= 3
36 ORDER BY produto_analitico, ABS(variacao_hhi) DESC, uf;

```


	uf	produto_analitico	1.2 hhi_2022h1	1.2 hhi_2026h1	1.2 variacao_hhi	1.2 vendedores_2026h1	1.2 lider_2026h1_pct
1	AP	ETANOL_HIDRATADO	8251	4200	-4052	4	59,2%
2	RS	ETANOL_HIDRATADO	4438	1056	-3381	33	23,4%
3	AC	ETANOL_HIDRATADO	4767	2870	-1896	8	52,7%
4	AC	GASOLINA_C	4233	2948	-1286	5	24,0%
5	RN	GASOLINA_C	2511	1237	-1274	21	
6	CE	GASOLINA_C	2765	1830	-935	23	

Fonte: captura da consulta executada no Databricks em 2026.

6.5 Preços de revenda


O indicador de preço foi construído em duas etapas. Primeiro, cada UF recebeu a mediana de suas medianas mensais no semestre. Depois, foi calculada a mediana entre as 27 UFs. Dessa forma, uma UF com maior quantidade de coletas não recebe peso proporcionalmente maior no indicador nacional.

Figura 12 - Mediana das medianas estaduais no primeiro semestre



Fonte: pesquisa de preços de revenda da ANP processada no Databricks.

Figura 13 - Resultado dos preços medianos estaduais no Databricks SQL



Fonte: captura da consulta executada no Databricks em 2026.

A gasolina C passou de R\$ 7,17 por litro no primeiro semestre de 2022 para R\$ 6,59 em 2026. O etanol hidratado passou de R\$ 5,70 para R\$ 4,99. As 27 UFs aparecem nos dois períodos. A quantidade de coletas caiu de 132.487 para 110.923 na gasolina e de 116.822 para 93.891 no etanol. O indicador descreve a amostra coletada; ele não representa um censo dos postos.

6.6 Associações entre volume concentração e preço

As correlações foram calculadas no nível de UF e primeiro semestre, com 27 observações por produto e ano. No etanol, a correlação entre o logaritmo do volume e o preço foi -0,7130 em 2022 e -0,7858 em 2026. A correlação entre HHI e preço foi positiva em todo o período, com 0,6235 em 2022 e 0,6632 em 2026.

Na gasolina, a associação entre volume e preço tornou-se mais negativa, de -0,1077 em 2022 para -0,4797 em 2026. A correlação entre HHI e preço mudou de -0,1753 para 0,1164, sem estabilidade suficiente para uma interpretação geral.

Tabela 14 - Correlações entre volume concentração e preço

Produto	Ano	UFs	corr log volume preço	corr HHI preço	corr Top 3 preço
Etanol	2022	27	-0,7130	0,6235	0,6609
Etanol	2026	27	-0,7858	0,6632	0,6147
Gasolina C	2022	27	-0,1077	-0,1753	-0,1824
Gasolina C	2026	27	-0,4797	0,1164	0,1713

Fonte: gold_fato_venda_empresa_uf_mes e gold_fato_preco_uf_mes.

Figura 14 - Correlações descritivas por produto e primeiro semestre no Databricks SQL

```

58 SELECT c.ano, c.produto_analitico, c.uf,
59        LN(c.volume_litros) AS log_volume,
60        c.hhi, c.top3_pct, p.preco_h1
61 FROM concentracao c
62 INNER JOIN preco p
63     ON c.ano = p.ano
64     AND c.uf = p.uf
65     AND c.produto_analitico = p.produto_analitico
66 )
67 SELECT ano, produto_analitico,
68        COUNT(*) AS ufs_comparaveis,
69        ROUND(CORR(log_volume, preco_h1), 4) AS corr_log_volume_preco,
70        ROUND(CORR(hhi, preco_h1), 4) AS corr_hhi_preco,
71        ROUND(CORR(top3_pct, preco_h1), 4) AS corr_top3_preco
72 FROM base
73 GROUP BY ano, produto_analitico
74 ORDER BY produto_analitico, ano;

```

	ano	produto_analitico	ufs_comparaveis	corr_log_volume_preco	corr_hhi_preco	corr_top3_preco
1	2022	ETANOL_HIDRATADO	27	-0.713	0.6235	0.6609
2	2023	ETANOL_HIDRATADO	27	-0.7466	0.6532	0.6151
3	2024	ETANOL_HIDRATADO	27	-0.7933	0.6887	0.6355
4	2025	ETANOL_HIDRATADO	27	-0.7258	0.6435	0.6617
5	2026	ETANOL_HIDRATADO	27	-0.7858	0.6632	0.6147
6	2022	GASOLINA_C	27	-0.1077	-0.1753	-0.1824
7	2023	GASOLINA_C	27	-0.2683	0.085	0.1273


Fonte: captura da consulta executada no Databricks em 2026.

Essas correlações mostram variação conjunta. Elas não isolam renda, tributação, frete, custo de produção, sazonalidade ou cobertura da pesquisa. Portanto, não permitem afirmar que concentração ou volume causou o preço observado.

6.7 Comparação entre SIMP e Logística 02


O SIMP foi incorporado como fonte complementar porque acrescenta agente regulado e mercado destinatário. A Logística 02 continua sendo a fonte principal do ranking por vendedor. As duas bases foram comparadas depois de agregadas por UF, produto e mês.

Figura 15 - Volumes nacionais do SIMP e da Logística 02 no primeiro semestre



Fonte: gold_comparacao_simp_logistica_uf_mes.

Figura 16 - Comparação entre SIMP e Logística 02 no mesmo recorte semestral



Fonte: captura da consulta executada no Databricks em 2026.

Na gasolina C, a diferença do SIMP em relação à Logística foi -0,188% em 2022 e -0,117% em 2026. No etanol, foi -11,567% e -20,279%. A proximidade da gasolina não torna

as bases intercambiáveis, e a diferença do etanol não foi corrigida. O pipeline preserva os dois valores e classifica a comparação como questão de escopo.

6.8 Market share por agente regulado e mercado destinatário


No SIMP, o denominador inclui os agentes regulados com volume positivo. Na gasolina C, Vibra, Ipiranga e Raízen tiveram 21,91%, 17,70% e 15,63%, totalizando 55,24%. No etanol, Ipiranga, Raízen e Vibra tiveram 14,40%, 14,35% e 13,85%, totalizando 42,60%. Os volumes das empresas coincidem com as linhas homônimas da Logística 02, mas as participações diferem porque o universo total de cada fonte não é o mesmo.

Tabela 15 - Maiores agentes regulados no primeiro semestre de 2026

Produto	Pos.	Agente regulado	milhões L	Participação
Gasolina C	1	Vibra	4.204,4	21,91%
Gasolina C	2	Ipiranga	3.397,3	17,70%
Gasolina C	3	Raízen	2.999,8	15,63%
Gasolina C	4	ALE	603,6	3,14%
Gasolina C	5	Federal Energia	456,0	2,38%
Etanol	1	Ipiranga	1.407,0	14,40%
Etanol	2	Raízen	1.401,5	14,35%
Etanol	3	Vibra	1.352,7	13,85%
Etanol	4	Avant	584,0	5,98%
Etanol	5	Integração	553,6	5,67%

Fonte: SIMP.

Figura 17 - Distribuição por mercado destinatário no SIMP em 2026 H1



Fonte: SIMP processado no Databricks.

Os postos bandeirados receberam 61,16% do volume de gasolina C e os postos de bandeira branca, 38,33%. No etanol, a relação se inverteu: bandeira branca respondeu por

51,62% e postos bandeirados por 46,31%. Consumidor final, TRR e TRRNI completaram o total. O resultado descreve o destino declarado na base e não o cadastro de bandeira de cada posto.

6.9 Escala municipal e reconciliação

A camada municipal foi mantida no período de 2022 a 2024. Em 2024, foram observadas 5.514 combinações município-produto com venda de gasolina C e 4.564 com venda de etanol. A pesquisa de preços cobriu 8,34% dessas combinações na gasolina e 10,04% no etanol. A baixa proporção confirma que a pesquisa é amostral e limita comparações municipais generalizadas.

Tabela 16 - Cobertura municipal de venda e preço

Ano	Produto	Com venda	Com preço	Publicáveis	Cobertura
2022	Etanol hidratado	4.533	457	444	10,08%
2023	Etanol hidratado	4.505	457	440	10,14%
2024	Etanol hidratado	4.564	458	446	10,04%
2022	Gasolina C	5.498	462	459	8,40%
2023	Gasolina C	5.503	461	459	8,38%
2024	Gasolina C	5.514	460	459	8,34%

Fonte: gold_cobertura_pesquisa.

Figura 18 - Cobertura municipal de vendas e preços no período de 2022 a 2024

ano	produto_analitico	combinacoes_com_venda	combinacoes_publicaveis	cobertura_publicavel_pct
2022	ETANOL_HIDRATADO	4533	444	9.79
2023	ETANOL_HIDRATADO	4505	440	9.77
2024	ETANOL_HIDRATADO	4564	446	9.77
2022	GASOLINA_C	5498	459	8.35
2023	GASOLINA_C	5503	459	8.34
2024	GASOLINA_C	5514	459	8.32

Fonte: captura da consulta executada no Databricks em 2026.

Na reconciliação entre Logística 02 e vendas municipais, 25 das 27 combinações estaduais da gasolina foram compatíveis em 2024. No etanol, apenas quatro UFs foram compatíveis em cada ano; as demais divergiram em escopo. Os anos de 2025 e 2026 ficaram sem base comparável, pois a fonte municipal termina em 2024.

7 Repositório público e reprodutibilidade

7.1 Conteúdo disponibilizado

O código e a documentação técnica foram publicados no repositório público Engenharia-de-Dados, pertencente ao perfil diasfabi7-prog. Essa publicação atende à orientação de entrega do professor e permite examinar o projeto sem depender do relatório. O repositório não contém os arquivos brutos da ANP nem credenciais; contém os meios para baixar novamente as fontes, inspecioná-las e executar o pipeline (Carvalho, 2026).

- README.md: apresenta o problema, o recorte, as fontes e a ordem de execução;
- config/: registra o ambiente de exemplo, o mapeamento de produtos, o agrupamento de empresas e as descrições do catálogo;
- data/: documenta a estrutura esperada para dados locais, sem versionar os arquivos brutos;
- docs/: reúne objetivo, cobertura das fontes, linhagem, modelo de dados, catálogo e roteiro de execução;
- notebooks/: contém setup, preparação, ingestão Bronze, transformação, qualidade, análises e validação;
- scripts/: contém os utilitários de download e inspeção dos arquivos oficiais;
- tests/: contém testes dos utilitários de coleta e inspeção;
- Makefile, pytest.ini e requirements-dev.txt: padronizam as verificações locais do código.

Na raiz foram publicados .gitignore, Makefile, README.md, pytest.ini e requirements-dev.txt. Em config/ foram incluídos ambiente.example.yml, catalogo_atributos.csv, empresa_grupo_mapeamento.csv e produto_mapeamento.csv. A pasta data/ contém apenas README.md. Em docs/ estão catalogo_dados.md, cobertura_fontes.md, execucao_databricks.md, fontes_e_linhagem.md, modelo_dados.md e objetivo.md. Essa relação descreve o conteúdo efetivamente destinado à avaliação, e não arquivos auxiliares usados para montar este relatório.

Os notebooks publicados correspondem às seis tarefas exibidas no grafo do job. O arquivo 00_setup_ambiente.sql cria a estrutura inicial; 00_preparar_arquivos_anp.py prepara os arquivos recebidos; 01_ingestao_bronze.py persiste o lote bruto; 02_transformacao_modelo.py constrói Silver e Gold; 03_qualidade_dados.py perfila atributos e aplica regras; 04_analises.sql responde às perguntas; e 05_validacao_implantacao.py confere objetos, cobertura e resultado final. A pasta scripts/ contém download_anp.py e inspect_raw.py; tests/ contém test_download_anp.py e test_inspect_raw.py.

7.2 Como o repositório reproduz a solução

A reprodução começa pelo download das fontes oficiais com `scripts/download_anp.py`. Em seguida, `scripts/inspect_raw.py` verifica nomes, extensões, conteúdo dos ZIPs e estrutura dos arquivos. Os dados são copiados para um Volume do Databricks, os caminhos são informados no arquivo de ambiente e os notebooks são executados na ordem definida no README. Essa separação entre código versionado e dados externos evita duplicar publicações oficiais e mantém a procedência explícita.

A pasta `config` torna visíveis as decisões que poderiam ficar escondidas no código, como a padronização de produtos e o agrupamento de empresas. A pasta `docs` explica as mesmas decisões em linguagem de documentação. Os testes locais verificam os utilitários de coleta e inspeção; as validações de negócio e qualidade são executadas dentro do Databricks, onde existem as tabelas completas.

Repositório público: github.com/diasfabi7-prog/Engenharia-de-Dados

7.3 Relação entre GitHub e Databricks

O GitHub registra a versão entregável do código; o Databricks registra a execução sobre os dados completos. Os notebooks do repositório foram mantidos com a mesma numeração do fluxo executado, o que permite relacionar cada arquivo à tarefa do job. Os identificadores do lote e da execução, apresentados na Seção 4.4, completam a ligação entre versão do código, arquivos de origem e tabelas produzidas.

A entrega foi dividida dessa forma para não transformar o repositório em armazenamento de dados. Quem avalia o trabalho encontra no GitHub o objetivo, as regras, o modelo, o catálogo, o código e os testes; no Databricks, encontra o Volume, as tabelas gerenciadas, o histórico do job e as consultas com resultados. As capturas deste relatório registram as partes visuais do ambiente que não ficam demonstradas apenas pela leitura dos arquivos versionados.

8 Respostas às perguntas do projeto

Tabela 17 - Respostas às perguntas do projeto

Pergunta	Situação	Resposta obtida
1	Respondida	Vibra liderou gasolina C; Ipiranga liderou etanol em 2026 H1.
2	Respondida	HHI e líder variam muito por UF; AP e RS mostram trajetórias distintas.
3	Respondida	As quatro empresas foram comparadas em primeiros semestres, sem consolidar variantes.
4	Respondida	Preços, coletas e 27 UFs foram medidos; a natureza amostral foi preservada.
5	Respondida com limite	Correlações descrevem associação, sem inferência causal.
6	Parcialmente respondida	Gasolina foi mais conciliável; etanol manteve divergência de escopo.
7	Respondida com limite	Cadastro contextualiza a rede atual e não reconstrói o passado.
8	Respondida	Ranking de agentes e destinos do SIMP foi calculado para 2026 H1.

Fonte: elaboração própria a partir dos resultados.

O objetivo geral foi atingido. O pipeline integrou as cinco fontes, manteve a linhagem e respondeu às perguntas centrais. A conciliação municipal do etanol foi classificada como resposta parcial porque os resultados indicaram diferença de escopo, e não porque o processamento ficou incompleto.

9 Limitações

Tabela 18 - Limitações e tratamento adotado

Limite	Risco	Tratamento
Volume declaratório	pode ser reprocessado pela ANP	lote, data e hash registrados
Vendedor, agente e bandeira	não são a mesma entidade	fatos e dimensões separados
Pesquisa de preços	amostral	coletas e cobertura acompanham a medida
Granularidades	mensal e anual	junções somente após agregação compatível
Camada municipal	termina em 2024	nenhuma extrapolação para 2025 ou 2026
Cadastro	fotografia atual	não usado para inferir bandeira histórica
Correlação	não estabelece causalidade	interpretação descritiva

Fonte: elaboração própria.

As limitações fazem parte do resultado. Quando duas fontes não coincidem, o pipeline mostra os valores paralelos e o status de comparação. Quando a cobertura de preços é baixa, a combinação permanece identificada. Essa abordagem evita transformar ausência de dado em ausência de mercado.

10 Autoavaliação

Consegui atingir o objetivo principal de construir um pipeline completo no Databricks, desde a coleta até as consultas analíticas. O resultado final vai além de uma tabela consolidada: cada camada pode ser auditada, os arquivos de origem têm hashes, as transformações estão separadas da ingestão, o catálogo é calculado na execução e as regras de qualidade registram as exceções encontradas.

A principal dificuldade foi compatibilizar fontes que tratam o mesmo mercado com conceitos diferentes. Vendedor da Logística 02, agente regulado do SIMP e bandeira de revenda não formam uma chave única. A decisão de mantê-los separados reduziu a quantidade de cruzamentos possíveis, mas evitou uma conclusão incorreta sobre participação de marca no varejo.

Outra dificuldade foi a diferença temporal entre as publicações. O núcleo mensal alcança junho de 2026, enquanto a base municipal termina em 2024. Mantive as perguntas originais e classifiquei a reconciliação municipal como parcial. Também precisei revisar a regra de duplicidade municipal: a primeira formulação considerava anos históricos fora do recorte, e a investigação levou ao ajuste e à reexecução da qualidade.

Como continuidade, pretendo incorporar novos meses quando as bases forem atualizadas, ampliar os produtos para diesel e GLP, criar um painel com filtros de UF e empresa e acrescentar variáveis externas, como frota, tributação e atividade econômica. Essas extensões exigem novas fontes e não foram usadas para explicar os resultados atuais.

11 Conclusão

O trabalho produziu um pipeline reprodutível para cinco conjuntos de dados públicos da ANP. A execução final materializou 52 tabelas, catalogou 650 atributos, executou 43 regras e terminou com validação aprovada. As análises mantiveram períodos comparáveis e não extrapolaram a cobertura municipal.

Entre os primeiros semestres de 2022 e 2026, os volumes declarados aumentaram nos dois produtos. A gasolina C apresentou liderança nacional mais concentrada entre Vibra, Ipiranga e Raízen. No etanol, as três primeiras ficaram próximas e perderam participação em relação a 2022. O HHI revelou diferenças estaduais que o ranking nacional não mostra.

A incorporação do SIMP acrescentou uma leitura por agente regulado e mercado destinatário. O volume de gasolina ficou muito próximo ao da Logística 02, enquanto o etanol apresentou diferença relevante e crescente. A pesquisa de preços completou o quadro, mas sua cobertura amostral permaneceu explícita. Assim, o projeto responde ao problema com medidas auditáveis e com limites de interpretação definidos.

Referências

- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Painel Dinâmico do Mercado Brasileiro de Combustíveis Líquidos. Brasília, DF: ANP, 2026a. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/paineis-dinamicos-da-anp/paineis-dinamicos-do-abastecimento/painel-dinamico-do-mercado-brasileiro-de-combustiveis-liquidos>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Dados abertos. Brasília, DF: ANP, 2026b. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Dados abertos de movimentação de derivados de petróleo e biocombustíveis. Brasília, DF: ANP, 2026c. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/dados-abertos-movimentacao-de-derivados-de-petroleo>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Série histórica de preços de combustíveis e de GLP. Brasília, DF: ANP, 2026d. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Vendas de derivados de petróleo e biocombustíveis. Brasília, DF: ANP, 2026e. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/vendas-de-derivados-de-petroleo-e-biocombustiveis>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Dados cadastrais dos revendedores varejistas de combustíveis automotivos. Brasília, DF: ANP, 2026f. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/dados-cadastrais-dos-revendedores-varejistas-de-combustiveis-automotivos>. Acesso em: 19 set. 2026.
- AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS. Base de dados utilizada no painel de combustíveis líquidos. Brasília, DF: ANP, 2026g. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/arquivos/mdpg/liquidos.zip>. Acesso em: 19 set. 2026.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 10520: informação e documentação: citações em documentos: apresentação. Rio de Janeiro: ABNT, 2023.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 14724: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro: ABNT, 2024.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2025.
- CARVALHO, Fabiola Dias. Engenharia de Dados: mercado brasileiro de combustíveis. GitHub, 2026. Disponível em: <https://github.com/diasfabi7-prog/Engenharia-de-Dados>. Acesso em: 19 set. 2026.
- DATABRICKS. What is the medallion lakehouse architecture? 2026. Disponível em: <https://docs.databricks.com/gcp/en/lakehouse/medallion>. Acesso em: 19 set. 2026.
- PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO. MVP: Minimum Viable Product. Rio de Janeiro: PUC-Rio, 2026. Material de orientação da disciplina.

Apêndice A Atendimento aos requisitos

Tabela 19 - Atendimento aos requisitos do professor

Requisito	Local	Evidência
Objetivo	Seção 1	problema, perguntas e recorte definidos antes das análises
Busca pelos dados	Seção 2.1	cinco fontes oficiais e abertas da ANP
Coleta	Seções 2.2 e 2.3	URLs, hashes, manifesto e Volume
Modelagem	Seção 3	constelação de fatos, dimensões, chaves e granularidades
Catálogo	Seção 3.4	650 atributos com perfil observado e domínios
Carga	Seção 4	job com seis tarefas e 52 tabelas persistidas
Qualidade	Seção 5	43 regras e tratamento das ocorrências
Solução do problema	Seções 6 e 8	resultados discutidos e respostas consolidadas
Evidências	Seções 2, 4, 5 e 6; Apêndice B	capturas de execução, cobertura, análises e qualidade
Autoavaliação	Seção 10	atingimento, dificuldades e trabalhos futuros
Repositório público	Seção 7	código, documentação, configurações e testes no GitHub

Fonte: elaboração própria com base no enunciado do MVP.

A matriz acima foi construída a partir do enunciado do MVP. Ela permite localizar os elementos avaliados sem substituir a explicação técnica apresentada no corpo do trabalho.

Apêndice B Matriz de evidências

As capturas foram distribuídas nas seções em que sustentam cada afirmação. Essa opção mantém a evidência próxima da discussão, conforme solicitado no enunciado do MVP, e evita um anexo composto por imagens sem interpretação.

Tabela 20 - Evidências e localização no relatório

Etapa	Local	Evidência registrada
Execução do pipeline	Figura 3	Job com seis tarefas, status Succeeded e 52 tabelas na linhagem
Cobertura temporal	Figura 1	54 meses para Logística 02, SIMP e preços; vendas municipais até 2024
Qualidade	Figuras 4 e 5	resumo das 43 regras e consulta da tabela de resultados
Volume nacional	Figuras 6 e 7	série comparável dos primeiros semestres
Market share	Figuras 8 e 9	ranking de vendedores e participações em 2026 H1
Concentração	Figura 11	HHI e participação do líder por UF
Preços	Figuras 12 e 13	medianas estaduais e quantidade de coletas
Correlações	Figura 14	associação descritiva entre preço, volume, HHI e Top 3
SIMP e Logística 02	Figuras 15 e 16	comparação paralela de volumes e diferenças de escopo
Escala municipal	Figura 18	cobertura de preço sobre combinações com venda

Fonte: elaboração própria.

O job final foi executado na conta fabidatabricks@gmail.com, em 19 de setembro de 2026. A execução 668282086141894 terminou com sucesso. As capturas analíticas exibem o código SQL e o resultado tabular utilizado na discussão, preservando o vínculo entre a consulta e a conclusão apresentada.